

Selección de variables, Verificación de supuestos, y preparación de datos.

La base de datos fue creada a partir de la unión entre tres distintas bases rendimientos (anuales), información agroclimática (anual) y latitud (municipio-departamento), filtrando de estas los departamentos de Cundinamarca y Nariño que son los selectos desde un inicio del proyecto. Se excluyen variables como altitud máxima y mínima en este paso dado que se tiene la altitud media.

Estas variables son información del estado del clima (precipitación, temperatura, etc.) y de los suelos (SPI) de acuerdo con cada departamento y municipio, calculando los registros anuales dado que no se cuenta con datos de rendimientos diarios o mensuales.


Dichas variables se describen a continuación:

Variable	Cálculo para creación de features	Interpretación
log1p_área sembrada	Logaritmo del area sembrada.	Area sembrada de café.
Precipitación acumulada anual (mm/año)	precip_mm_mes = tp * 1000 * días_del_mes; luego suma anual por municipio.	Agua total recibida durante el año.
Temperatura media anual (°C)	t2m_c = t2m - 273.15; luego promedio anual por municipio.	Temperatura promedio anual del municipio.
Máximo de la temperatura media mensual (°C)	Se calcula temperatura mensual media por municipio y se toma el máximo mensual dentro del año.	Mes más cálido del año en términos de temperatura media mensual, indica estres termico
Mínimo de la temperatura media mensual (°C)	Se calcula temperatura mensual media por municipio y se toma el mínimo mensual dentro del año.	Mes más frío del año.
Humedad relativa media anual (%)	Se convierten temperatura y punto de rocío a °C; se calcula RH con fórmula psicrométrica; se limita entre 0 y 100; luego promedio anual.	Humedad promedio del aire, indica estres hidrico.
log1p_radiación solar acumulada anual (mj/m²/año)	Log de rad_mes = (ssrd * días_del_mes) / 1_000_000; luego suma anual por municipio.	Energía solar acumulada en el año. Afecta fotosíntesis, crecimiento y productividad potencial.
Humedad volumétrica media anual del suelo capa 1 (m³/m³)	Promedio espacial mensual dentro del municipio; luego promedio anual.	Contenido de agua en la capa superficial del suelo. Indica sequía agrícola inmediata y disponibilidad hídrica superficial.
Humedad volumétrica media anual del suelo capa 2 (m³/m³)	Promedio espacial mensual dentro del municipio; luego promedio anual.	Contenido de agua en una capa más profunda del suelo. Indica reserva hídrica más persistente.
Evaporación potencial acumulada anual (mm/año)	pev_mm_mes = abs(pev) * 1000 * días_del_mes; luego suma anual por municipio.	Demanda atmosférica potencial de agua.
SPI3_mean_anual	SPI_3 se calcula con precipitación acumulada móvil de 3 meses; luego se promedia dentro del año.	Condición hídrica promedio a escala trimestral.

SPI3_min_anual	Mínimo mensual de SPI_3 dentro del año.	Peor episodio trimestral de sequía/humedad del año.
SPI3_meses_bajo_m1	Conteo anual de meses con SPI_3 < -1.	Número de meses con sequía moderada o peor a escala de 3 meses.
SPI6_mean_anual	SPI_6 se calcula con precipitación acumulada móvil de 6 meses; luego promedio anual.	Condición hídrica promedio semestral.
SPI6_min_anual	Mínimo mensual de SPI_6 dentro del año.	Peor episodio semestral de sequía del año.
SPI6_meses_bajo_m1	Conteo anual de meses con SPI_6 < -1.	Duración anual de sequía moderada o peor a escala semestral.
SPI12_mean_anual	SPI_12 se calcula con precipitación acumulada móvil de 12 meses; luego promedio anual.	Condición hídrica anual promedio.
SPI12_min_anual	Mínimo mensual de SPI_12 dentro del año.	Peor condición hídrica anual acumulada.
SPI12_meses_bajo_m1	Conteo anual de meses con SPI_12 < -1.	Número de meses con sequía anual acumulada moderada o peor.
SPI3_dic	Se filtran registros de diciembre y se toma SPI_3.	Estado hídrico trimestral al cierre del año.
SPI6_dic	Se filtran registros de diciembre y se toma SPI_6.	Estado hídrico semestral al cierre del año.
SPI12_dic	Se filtran registros de diciembre y se toma SPI_12.	Balance hídrico anual acumulado al cierre del año.
SPI1_floracion	Nariño: promedio septiembre-octubre. Cundinamarca: promedio febrero-marzo y agosto-septiembre.	Condición hídrica mensual durante floración.
SPI3_floracion	Mismos meses de floración que SPI1_floracion, usando SPI_3.	Condición hídrica acumulada de 3 meses durante floración.
SPI1_llenado	Nariño: diciembre. Cundinamarca: abril-julio y diciembre.	Condición hídrica mensual durante llenado.
SPI3_llenado	Mismos meses de llenado que SPI1_llenado, usando SPI_3.	Condición hídrica acumulada de 3 meses durante llenado.
altitud_media_m	No se requiere calculo	Altitud promedio municipal.
Rendimiento	Rendimiento calculado mendiente produccion / area cosechada.	Producción por unidad de área del municipio-año.

Dicha base final cuenta con 1.481 observaciones y 31 variables, los cuales son datos tipo panel siendo que cada observación representa información anual agroclimática de cada municipio desde el periodo 2008 hasta el 2024. Se detecta que ninguna variable presenta valores nulos o vacíos, también que no existen observaciones duplicadas. De los municipios observados se tienen 92 distintos y sus rendimientos tienen valor máximo de 1.9 y un mínimo de 0.06, con una media de 0.9, lo que sugiere que en promedio los municipios están por debajo del rendimiento de al menos 1, recordar que esta unidad indica que se produce lo que se cosecha, por ende, se identifica que para la media de municipios se

produce menos de la cosecha, siendo el periodo 2019 el que mayor rendimiento tiene (ver anexo).



Boxplot Rendimientos por año.

Se determina la variable rendimiento lag 1, lag 2 y lag 3 de acuerdo con los rezagos anuales para identificar si existe entre el periodo t y el t+1





Tabla Rendimientos por año.

De las variables de clima como radiación solar, precipitación media y evaporación, que capturan factores climáticos, se evidencia que la radiación si es mayor a su vez el rendimiento aumenta, en cambio si la precipitación se mantiene en nivel entre 2000 mm y 4000 mm, el rendimiento puede ser superior al 0.5, al igual que la evaporación. Con ello se destaca que la producción se ve afectada positivamente si se mantiene un nivel considerable de radiación solar, de precipitación y de evaporación.



Scatter plot rendimientos por variable clima.

Al tratarse de variables tipo panel, se identifican 1376 con rendimiento t+1 valido, dado que los datos están limitados hasta 2024. Con ello se valida si existen saltos temporales, es decir si en la base de datos hay municipios cuyo tiempo t+1 es mayor o igual a dos periodos siguientes. Se identifican 79 municipios que cuentan con serie continua, 13 de ellos tienen saltos temporales siendo los municipios Cumbal y La Llanada del departamento Nariño los que tienen un salto significativo de 7 periodos (ver sección Saltos temporales -EDA-)




Tabla Municipios y periodos.

Se identifica persistencia en el rendimiento es decir que el rendimiento tiene correlación con el rendimiento $t+1$ de 0.5916 significa que, en promedio, los municipios con alto rendimiento en t tienden a seguir teniendo rendimientos relativamente altos en $t + 1$, y los municipios con bajo rendimiento en t tienden a mantenerse relativamente bajos en el siguiente periodo




Tabla Rendimiento T vs rendimiento T+1.


Usando la prueba ADF evalúa si una serie tiene raíz unitaria, es decir que la serie evoluciona a raíz del tiempo de acuerdo con:

Hipótesis:

H_0 : la serie tiene raíz unitaria, no es estacionaria

H_1 : la serie es estacionaria

Por lo que observaciones con p-values superiores a 0.05 indicaría que no es estacionaria, rechazando la hipótesis alternativa.



Prueba ADF por municipios.

De acuerdo con la gráfica anterior se determina que existen 60 municipios con serie no estacionaria mientras 31 si tendrían cierto grado de estacionariedad. Entonces el rendimiento no se comporta igual en todos los municipios a través del tiempo. En aproximadamente dos tercios de los municipios, el rendimiento parece tener tendencia, persistencia, cambios estructurales o una media que no es completamente estable. Dado que son datos anualizados es esperable que no se detecte estacionariedad, pues no se tienen muchos periodos de análisis que logren determinar si la serie es estacionaria, por ello se tomaran los datos como tipo panel no estacionarios.

Con lo anterior se procede a validar si existe colinealidad entre variables, de acuerdo con la prueba de inflación de varianza VIF (valores mayores a 10 significa alta colinealidad).




Tabla VIF.

Las variables que presentan un VIF mayor a 10, será descartadas de los modelos, pero antes de ello se validará mediante PCA (Análisis de componentes principales) si existe alguna relevancia de estas para mantener alguna pese a su alta colinealidad.




Tabla PCA.

Los componentes por usar de acuerdo con PCA son entre 10 y 15 componentes, para obtener una explicación de la varianza entre el 90% y el 95% reduciendo en un 50% el total

de variables existentes. Se valida si con ello los modelos presentaran un mejor performance dado que se puede perder interpretabilidad y variabilidad.




Tabla Comparación modelo con PCA y sin PCA.

Con los resultados obtenidos se determina que no es viable el uso de PCA para reducir la dimensión dado que se obtienen resultados similares y se reduce la interpretabilidad del modelo al incorporar variables mediante PCA.

Dado lo anterior, existen muchas limitantes desde obtener datos de rendimientos diarios o mensuales para tener mas observaciones hasta tener variables como abono usado en la cosecha, tipo de semilla, variables de ambiente como posibles depredadores, tipo de suelo, cantidad de terreno abierto o cerrada; cuyos datos son relevantes para determinar la salud de un cultivo de café y si el rendimiento de su cosecha es afectado negativamente cuyo caso apalancaría el uso de la póliza y una posible activación de pago de coberturas.